Uczenie maszynowe
Projekt 1 - etap pierwszy

Temat: analiza recenzji IMDb i ocen filmów MovieLens

Data opracowania: 27.10.2026

Osoba	Nr indeksu	Podział odpowiedzialności
Andrei Rastsiahayeu	71629	Koordynacja, dokumentacja źródeł, kompletność raportu
Vadym Karkhut	71513	Dane MovieLens, statystyki opisowe i wykresy ocen
Yulia Khrystonko	72072	Dane IMDb, przygotowanie tekstu i analiza długości
Kateryna Ivanchenko	72646	Pytania badawcze, interpretacja i plan metod
Alisa Kosenkova	71510	Reprodukowalność, kontrola wyników i przygotowanie repozytorium

1. Cel projektu

W projekcie analizujemy dwa rodzaje opinii: tekstowe recenzje z IMDb i liczbowe oceny z MovieLens. Chcemy opisać dane, znaleźć widoczne zależności oraz przygotować pytania do dalszej pracy z modelami uczenia maszynowego.

Pytania badawcze

1. Czy pozytywne i negatywne recenzje różnią się długością i używanymi słowami?
2. Jak rozkładają się oceny MovieLens i jaki mają związek z rokiem premiery?
3. Czy w kolejnym etapie uda się rozpoznawać sentyment recenzji lepiej niż prostą metodą bazową?

Wykorzystane dane

Mamy 200 recenzji IMDb oraz 200 ocen MovieLens. Plik MovieLens_filmy zawiera te same oceny co MovieLens_liczby, ale z nazwami filmów. Są to dwa zbiory danych, mimo że zapisano je w trzech plikach Excel.

Jedna recenzja nie jest tym samym co jeden film, a jedna ocena MovieLens oznacza opinię konkretnego użytkownika o konkretnym filmie. Nie łączymy IMDb i MovieLens według numerów wierszy.

Na tym etapie wykonaliśmy analizę danych i kontrolę ich poprawności. Uczenie modeli oraz interfejs z predykcjami należą do kolejnego etapu.

2. Źródła i przygotowanie danych

IMDb

Recenzje pochodzą z Large Movie Review Dataset v1.0 (Maas i in., 2011), udostępnionego również jako stanfordnlp/imdb na Hugging Face. Z części train wybrano po 100 recenzji negatywnych i pozytywnych. Użyto jednego generatora random.Random(42): najpierw losowanie w klasie 0, potem w klasie 1, a następnie przetasowanie indeksów.

Nazwy i identyfikatory tytułów ustalono na podstawie oryginalnego archiwum recenzji oraz metadanych IMDb pobranych 25.10.2026. Podczas przygotowania danych 11 recenzji zastąpiono innymi prawdziwymi recenzjami tej samej klasy, ponieważ ich pierwotnych ID nie znaleziono w pobranych metadanych. Wykaz zmian i końcowe pliki źródłowe zapisano w manifeście.

Etykiety pochodzą ze źródła: negatywna recenzja ma oryginalną ocenę do 4/10, a pozytywna od 7/10. W tym zbiorze nie ma klasy neutralnej. Równowaga 100/100 jest wynikiem doboru danych.

MovieLens

Zbiór MovieLens 100K zawiera 100 000 ocen od 943 użytkowników dla 1682 filmów. Wybrano 200 rekordów z u.data poleceniem random.Random(42).sample(range(100000), 200). Rok premiery i nazwę filmu dołączono z u.item według ID filmu. Są to historyczne dane z lat 1997-1998.

Znaczenie kolumn

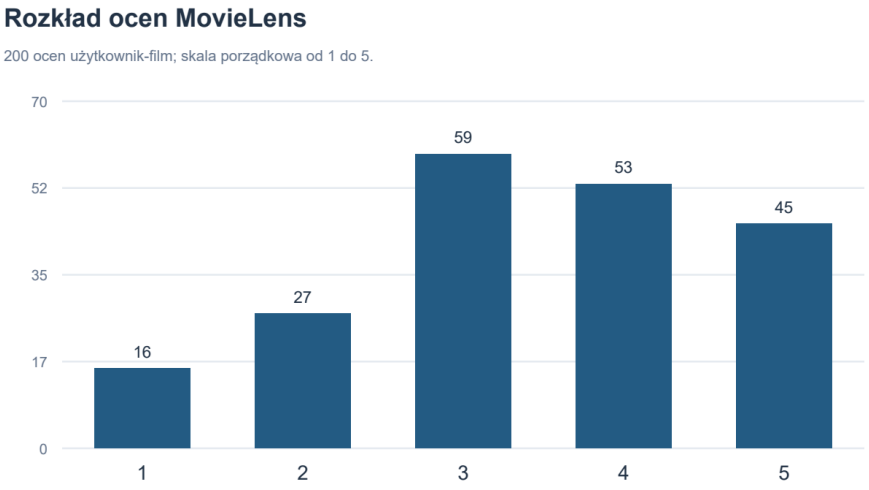
Plik / kolumny	Znaczenie
IMDb: tytul_filmu, id_imdb, link_imdb	Nazwa tytułu, jego identyfikator i link do strony IMDb.
IMDb: tekst_recenzji, sentyment	Oryginalny tekst angielski oraz etykieta: pozytywny albo negatywny.
MovieLens: id_uzytkownika, id_filmu	Identyfikatory użytkownika i filmu. Ich wartości nie oznaczają wielkości cechy.
MovieLens: ocena	Ocena użytkownika w skali od 1 do 5.
MovieLens: czas_unix	Czas wystawienia oceny w sekundach od 01.01.1970, UTC.
MovieLens: rok_premiery	Rok premiery, odrębny od daty wystawienia oceny.

Oryginalne pliki Excel zachowano bez zmian. Do analizy tekstu usunięto znaczniki HTML, zdekodowano encje i ujednolicono odstępy. Liczbę słów zmierzono przed pomijaniem stopwords. Przy analizie słownictwa zachowano przeczenia, np. not.

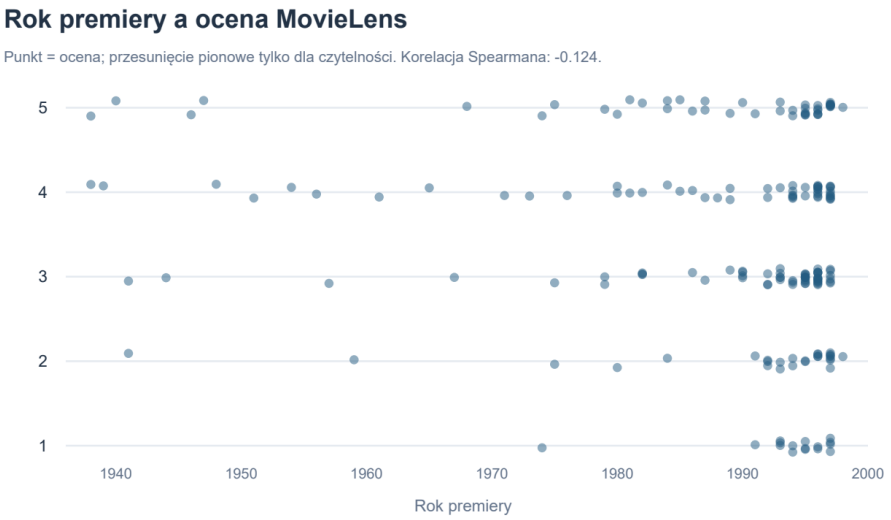
Dane przygotowano 25.10.2026. Pełną kontrolę powtórzono 27.10.2026. Dokładną kolejność rekordów, hashe i pochodzenie każdej recenzji zapisano w sources/source_manifest.json.

3. Analiza ocen MovieLens

Miara	Wynik
Liczba ocen / filmów / użytkowników	200 / 172 / 161
Średnia / mediana	3,42 / 3
Odchylenie standardowe	1,20
Oceny 4 i 5	98 z 200, czyli 49,0%



Najczęstsza ocena to 3: występuje 59 razy, czyli w 29,5% rekordów. Średnia 3,42 opisuje wybrane oceny użytkowników, a nie średnią po wszystkich filmach.

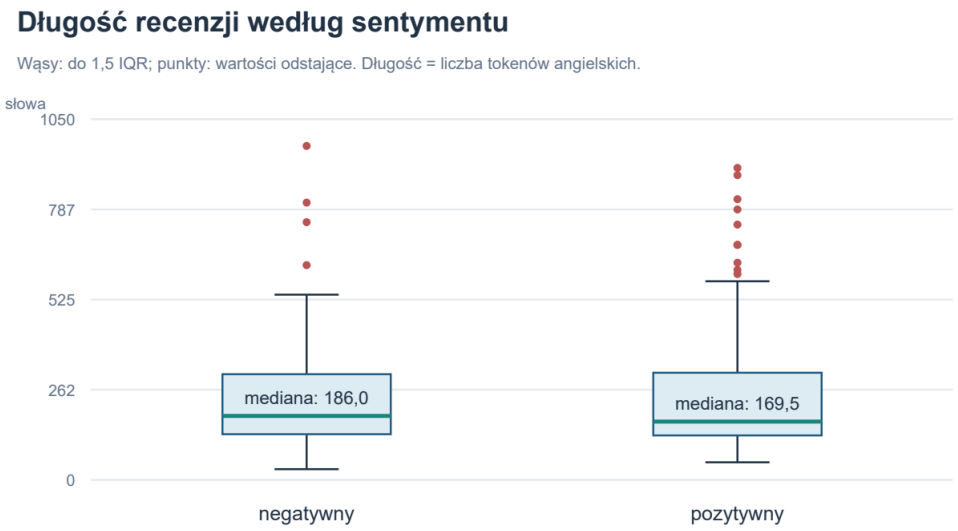


Współczynnik korelacji rang Spearmana między rokiem premiery a oceną wynosi -0,124. W próbie zależność jest słaba i ujemna. Po uśrednieniu ocen dla każdego filmu wynosi -0,164. Nie jest to dowód, że starsze filmy są lepsze.

Aż 150 filmów ma w próbie tylko jedną ocenę. Użytkownicy i filmy powtarzają się, dlatego zależność opisujemy bez testu istotności zakładającego niezależność wszystkich wierszy. 141 ocen dotyczy filmów z lat 90.; najpóźniejsza premiera to 1998 r.

4. Analiza recenzji IMDb

Miara	Negatywne	Pozytywne
Liczba recenzji	100	100
Średnia liczba słów	237,86	258,92
Mediana liczby słów	186,0	169,5
Odchylenie standardowe	162,11	204,15
Minimum / maksimum	31 / 972	51 / 908



Pozytywne recenzje mają większą średnią długość, ale mniejszą medianę. Długie teksty wpływają na średnią, a oba rozkłady mocno się nakładają. Sama długość nie wystarcza więc do pewnego rozpoznania sentymentu.

Przykładowe słowa w obu klasach

Słowo	Recenzje negatywne	Recenzje pozytywne
bad	43	19
great	20	43
good	38	37
not	66	60

Tabela pokazuje liczbę recenzji zawierających słowo, najwyżej raz na recenzję. Słowa good i not pojawiają się w obu klasach, dlatego przy dalszej klasyfikacji trzeba uwzględnić kontekst.

200 recenzji dotyczy 189 tytułów. Według metadanych 167 recenzji dotyczy typu movie, a 33 innych typów, np. filmów telewizyjnych i seriali; jedna dotyczy typu videoGame. Zachowano zebraną próbę i opisano ten zakres zamiast usuwać rekordy po analizie.

5. Kontrola, wnioski i dalsza praca

Kontrola poprawności

Sprawdzono wszystkie 200 recenzji i 200 ocen oraz zgodność obu plików MovieLens. Nie znaleziono braków ani powtórzonych pełnych wierszy. Teksty, etykiety, oceny i ID porównano z archiwami źródłowymi. Nazwy 189 tytułów potwierdzono w zapisanym pliku metadanych IMDb. Nie było potrzeby zmiany wartości w arkuszach.

Wnioski

1. Długość recenzji różni się opisowo między klasami, ale rozkłady nakładają się. Widać też różnice słownictwa.
2. W MovieLens dominują oceny 3-5. Związek oceny z rokiem premiery jest słaby.
3. Skuteczność automatycznego rozpoznawania sentymentu sprawdzimy dopiero podczas uczenia modeli.

Próby po 200 rekordów są małe. IMDb dobrano celowo po 100 rekordów każdej klasy, a 11 rekordów zastąpiono według dostępności metadanych. Wyników nie traktujemy jako opinii wszystkich widzów. Zbiory IMDb i MovieLens analizujemy osobno.

Linki i odtwarzanie

Kontrola adresów jest w results/kontrola_linkow.json. IMDb ogranicza automatyczny dostęp, dlatego odpowiedzi 202/403 nie oznaczają usunięcia tytułów. Jeden adres w oryginalnym tekście recenzji (B91) zwraca 404; nie zmieniono autentycznej recenzji. Część źródeł była niedostępna z powodu błędów połączenia lub certyfikatu.

Instrukcja uruchomienia znajduje się w README.md. Wyniki można odtworzyć poleceniem python src/run_all.py. Archiwa do kontroli offline są w data/raw; do zwykłego przeliczenia analizy wystarczą trzy arkusze.

Repozytorium GitHub: https://github.com/Rastythekidd/ml-imdb-movielens

Źródła

[1] Maas A. L. i in. (2011), Learning Word Vectors for Sentiment Analysis, ACL, s. 142-150. https://aclanthology.org/P11-1015/

[2] Dane IMDb: https://huggingface.co/datasets/stanfordnlp/imdb. Źródło pierwotne: https://ai.stanford.edu/~amaas/data/sentiment/

[3] MovieLens 100K: https://grouplens.org/datasets/movielens/100k/. Harper F. M., Konstan J. A. (2015), The MovieLens Datasets: History and Context, ACM TiiS 5(4), art. 19. DOI: 10.1145/2827872.

[4] Metadane IMDb: https://developer.imdb.com/non-commercial-datasets/. Zapis wykorzystany w projekcie: 25.10.2026.